《Extrinsic Hallucinations in LLMs》精读笔记

> 原文：Lilian Weng，Lil'Log，2024-07-07，https://lilianweng.github.io/posts/2024-07-07-hallucination/ 本笔记为中文学习笔记，以要点归纳和个人解读为主，不是原文译文；公式、数据与细节请以原文为准。

一句话结论

外在幻觉是指输出既没有上下文依据，也不符合世界知识。要减少它，模型得做到两件事：说真话，以及不知道时承认不知道。围绕这两点，文章系统梳理了成因、检测方法和缓解方法三条线。

1. 定义与范围

- 作者把"幻觉"收窄为：模型输出是编造的，既不忠实于给定上下文，也没有世界知识支撑。
- 两类幻觉：
  - 上下文内幻觉：输出与上下文里的源内容不一致。
  - 外在幻觉：输出应当有预训练数据（可以看作世界知识的代理）作依据。逐条检索预训练语料太贵，所以实际做法是要求输出可以被外部知识验证。
- 本文只讨论外在幻觉。

2. 幻觉从哪来

2.1 预训练数据

互联网语料天然包含过时、缺失、错误的信息。模型只是最大化似然，会把这些错误一并记住。

2.2 微调阶段引入新知识

- 核心参考：Gekhman et al. 2024。他们按模型"多大概率答对"，把闭卷问答样本分成 HighlyKnown、MaybeKnown、WeaklyKnown、Unknown 四档。
- 关键发现：
  1. Unknown 样本的拟合速度明显慢于 Known 样本。
  2. 开发集最优点出现在"大部分 Known 已学会、Unknown 只学会一小部分"的时候；Unknown 学多了，幻觉就开始增加。
  3. Known 里面，MaybeKnown 样本对整体效果的贡献比 HighlyKnown 更大。
- 启示：想靠小规模 SFT 给模型"灌新知识"有风险。

3. 如何检测幻觉

3.1 检索增强评测

方法	核心做法	要点
FactualityPrompt（Lee et al. 2022）	以维基百科为事实依据	两个指标：命名实体错误率（越低越好）、蕴含比例（越高越好），都与人工标注相关；模型越大表现越好
FActScore（Min et al. 2023）	把长文本拆成"原子事实"逐条核验	检索 + LLM 优于不带上下文的 LLM；越冷门的实体、越靠后生成的事实，错误率越高
SAFE（Wei et al. 2024）	让 LLM 作为 Agent 多轮调用 Google 搜索来核验每条原子事实	与人工一致率约 72%，分歧时胜过人工约 76%，成本约为人工的 1/20；指标 F1@K 同时兼顾准确率（事实是否被支持）和召回（事实是否足够多）
FacTool（Chern et al. 2023）	标准事实核查流水线：抽取主张 → 生成查询 → 调工具取证 → 判定	覆盖问答、代码、数学、文献综述等任务

F1@K 的直观理解：用 S 表示被支持的事实数，N 表示不被支持的事实数。准确率 = S/(S+N)；召回 = min(S/K, 1)，K 是"期望提供多少条事实"的上限；两者取调和平均。

3.2 基于采样的检测

- SelfCheckGPT（Manakul et al. 2023）：对同一个问题多次采样，检查答案之间是否一致。只需要黑盒访问，不需要外部知识库，也不需要 logprob。
- 一致性可以用 BERTScore、NLI 或直接提问（是 / 否）来衡量，文中实验里提问的方式效果最好。

3.3 对"未知"的校准

- TruthfulQA（817 题、38 个主题）：题目专门围绕人类常见误解对抗式构造。论文测试时最好的模型约 58%，人类约 94%；在这个基准上，模型越大反而越"不诚实"，因为它把常见误解学得更牢。
- SelfAware：1,032 道不可回答题和 2,337 道可回答题。把"判断能不能答"当作二分类任务，模型越大表现越好。
- Kadavath et al. 2022：在带字母选项的多选题上，预训练模型的概率校准良好；RLHF 会破坏校准，调高采样温度能部分恢复。
- Lin et al. 2022（CalibratedMath）：比较了三种置信度表达：口头表达的数字或等级、答案 token 的 logprob、额外追加一个 True/False token 的概率。口头置信度在分布迁移下泛化得不错；few-shot 弱于微调，50-shot 接近微调效果。

3.4 间接询问

- Agrawal et al. 2023 专门研究"编造参考文献"。
- 直接问："这篇论文存在吗？"间接问："这篇论文的作者是谁？"
- 原理：如果文献是编的，多次采样得到的作者名很难一致。实验中间接询问效果更好，更大的模型也更少编造。

4. 缓解幻觉的方法

作者把方法分成几大类（文中明确略过了神经元编辑等可解释性方法）。

4.1 检索增强，并在生成后编辑或加上归因

- RARR：先"调研"（生成查询、搜索、每个查询保留最相关的证据），再"修订"（逐条判断证据是否与文本冲突，冲突时做最小改动），最后输出修订文本和归因报告。评价看两点：可归因性（AIS 分）和保留度（改动尽量少）。
- FAVA：检索器加编辑器，编辑器需要微调。训练数据的做法是往维基段落里人为插入各类错误，合成"原文 / 带错文本 / 标注后的正确修订"三元组。
- RR（Rethinking with Retrieval）：不做编辑。先用思维链采样多条推理路径，为每条路径检索知识（BM25 加 MPNet 重排），再用蕴含、矛盾、相似度综合打分，选出最"忠实"的答案。
- Self-RAG：端到端训练模型输出四种反思 token：是否检索（Retrieve）、文档是否相关（IsRel）、输出是否有依据（IsSup）、输出是否有用（IsUse）。按片段逐段生成，必要时并行检索多个文档，再择优。

4.2 行动链：不依赖外部检索的自我验证

- CoVe（Chain-of-Verification） 分四步：先写初稿 → 规划核验问题 → 执行核验 → 输出修订稿。
    - 执行核验有几种变体：与规划合并（Joint）、两步分开（2-step）、每个问题单独回答（Factored）、单独回答后再交叉比对（Factor+Revise）。
    - 关键洞察：如果初稿留在上下文里，模型会重复同样的幻觉，所以把核验问题拆开、独立回答效果更好。
    - 其他发现：指令微调和思维链本身并不能减少幻觉；短问题比长问题答得准；模型自由生成的核验问题优于模板化问题；开放式问题优于是非题。
- RECITE：先让模型"背诵"相关知识，再基于背诵内容作答，相当于把 Transformer 的记忆当检索器用。效果接近 BM25 检索，但与使用标准答案段落仍有差距。

4.3 采样策略

- Factual-nucleus 采样（Lee et al. 2022）：假设句子越往后，随机性对事实性的伤害越大，所以在一句话内逐 token 衰减 top-p，同时设一个下限，避免退化成贪心解码。
- ITI（推理时干预）：用线性探针找出与"真实性"强相关的少数注意力头，推理时把这些头的激活沿"真实方向"平移。

4.4 面向事实性的微调

- Lee et al. 2022：TopicPrefix（每句话前加文档标题）；句子补全损失（只对句子后半段计损失，切分点取句长一半左右效果最好）。
- FLAME（Lin et al. 2024）：事实性感知的 SFT 和 DPO。要点是用模型自己生成的回答构

造训练数据，避免把模型不知道的知识硬塞进去。图中还指出，RLHF 会因人类偏好更长、更详细的回答而损害事实性。

- Factuality Tuning（Tian & Mitchell et al. 2024）：对同一 prompt 采样多个回答，用有参考（检索维基加 NLI）或无参考（模型自身置信度）的方式打分，构造偏好对，再做 DPO；基于 FActScore 的版本提升最大。

4.5 面向归因的微调

- WebGPT：在文本浏览器环境里搜索，可以引用网页片段作为参考。先用人类示范做行为克隆，再用奖励模型做强化学习和 best-of-n 拒绝采样。结论是强化学习带来的提升很有限。
- GopherCite：和 WebGPT 类似，但示范数据由 few-shot 提示生成，并配合奖励模型重排；还引入选择性预测，奖励低于阈值时直接回答"我不知道"。

5. 附录中的评测基准速查

基准	规模 / 特点
TruthfulQA	817 题，38 个主题，针对人类常见误解对抗式构造
FactualityPrompt	事实性与非事实性提示，以维基百科为依据
SelfAware	1,032 道不可回答题 + 2,337 道可回答题
LongFact	2,280 条长文本事实性提示，覆盖 38 个主题
HaDes	扰动维基文本后做二分类幻觉检测
FEVER	约 18.5 万条主张，标签为支持 / 反驳 / 信息不足
FAVABench	200 条提示 × 3 个回答，细粒度标注错误类型

6. 对本仓库 web-search-agent-go 的启示（个人解读）

- web-search-agent 本质上就是在走"检索增强"这条路。可以借鉴 SAFE 或 FActScore 的思路，在验收中把最终答案拆成原子事实，逐条对照 observation 检查。
- CoVe 的"独立核验"提示我们：做答案自检时，最好不要把初稿放在同一上下文里。
- SelfCheckGPT 式的多次采样一致性检查，可以作为 `experiment12` 多次尝试（attempts）结果的补充分析维度。
- "不知道就说不知道"：失败文案和 `IsFailureAnswer` 的设计正是在显式建模"放弃回答"，这与后文 OpenAI 论文的观点呼应。