《Why Language Models Hallucinate》精读笔记

> 原文：Adam Tauman Kalai、Ofir Nachum、Santosh S. Vempala、Edwin Zhang（OpenAI / Georgia Tech），arXiv:2509.04664，2025-09-04。 本笔记为中文学习笔记，以要点归纳和个人解读为主，不是原文译文；定理的严格表述、证明（附录）与细节请以原文为准。

一句话结论

幻觉并不神秘，它有两个来源：

- 起源：预训练阶段，生成错误在统计上等价于二分类里的误分类，只要有交叉熵目标就会自然出现。
- 延续：后训练阶段，主流评测用 0/1 打分，"不知道"得 0 分，猜错也只得 0 分，于是模型被训练成应试型选手，不确定时就去猜。

作者主张的解法是"社会—技术"层面的：与其再造一个新的幻觉评测，不如修改现有主流基准的打分方式，不再惩罚表达不确定。

1. 引子：学生考试的类比

- 例子：问模型"作者某人的生日是哪天，知道的话只回答 DD-MM"，某开源 SOTA 模型三次给出三个不同的错误日期；问作者的博士论文题目，三家主流模型都编造了题目和年份。
- 类比：学生在选择题上不会就猜，在简答题上还会"蒙"一个听起来合理的答案。0/1 计分下，猜的期望得分总是高于留空。人类在考场之外会从"吃亏"中学会表达不确定，而模型几乎一直处在"考试模式"。

2. 预训练为什么必然出错

2.1 从生成到分类的归约

- 设所有"看起来合理"的字符串为 X，分为错误集合 E 和有效集合 V。
- 定义一个辅助的二分类问题 IIV（Is-It-Valid，"这是有效输出吗？"）：训练和测试分布都是一半有效样本、一半从 E 里均匀抽的错误样本。
- 任何语言模型都可以当作 IIV 分类器用：看模型给这个字符串的概率是否超过阈值 1/|E|。
- 核心关系（直观版）：

  生成错误率 ≥ 2 × IIV 误分类率

  严格版本里还要减去两项：一项是 |V|/|E|（有效答案相对错误答案的比例，通常很小），另一项是校准偏差 δ。
- 直觉："生成一个正确答案"比"判断一个答案对不对"更难，因为生成隐含着要对每个候选都做一次判断。所以，凡是二分类里导致误分类的因素，都会传导为生成错误。

- 分析不依赖 Transformer 或"下一个词预测"，所以对推理模型、带检索的模型同样成立。

2.2 为什么校准偏差 δ 在预训练后很小

- δ 衡量的是：模型认为"高概率"的那部分样本，在模型分布和真实分布下的占比差多少。
- 巧妙之处：δ 恰好等于交叉熵损失对一个简单缩放参数的导数。只要优化到局部最优，这个导数就接近 0，也就是说标准交叉熵目标天然会让模型被校准。
- 由此推出一个反直觉的结论：一个从不犯错的基础模型必然是不校准的。换句话说，只要按标准方式预训练，错误就会出现。实证上，GPT-4 预训练模型在多选题上校准良好，RL 之后反而失去了校准。
- 作者强调"幻觉不可避免"只对基础模型成立：一个只会查问答库、做算术、其余一律回答"我不知道"的系统就不会幻觉，但它显然不是好的密度估计器。

2.3 带提示词的推广

把样本推广为"提示 + 回答"的形式，结论不变（论文中的定理 1），前面的无提示版本只是它的特例。

3. 三类具体的错误来源

3.1 任意事实（认知不确定性）

- 当数据里没有可学的规律时（比如某个普通人的生日），模型只能靠"见没见过"。
- 单例率（singleton rate）：训练数据中只出现过一次的事实（不计"我不知道"）所占的比例。它借鉴了图灵和 Good 提出的"缺失质量"估计，也就是用只见过一次的样本比例，来估计还没见过的样本有多少。
- 定理 2 的直观含义：幻觉率大约不低于单例率。例如，如果 20% 的生日事实在训练数据里只出现过一次，那么基础模型至少会在大约 20% 的生日问题上产生幻觉。而像爱因斯坦生日这种被反复提及的事实，模型很少出错。
- 这个结论推广了作者 2024 年的早期工作，新增了对提示词和"我不知道"的处理。

3.2 模型能力不足

- 模型族本身表达不了目标概念，或者虽然表达得了但拟合得不好。
- 例子：三元语法模型（trigram）无法根据前文的 "She / He" 正确选择 "her mind / his mind"，任何三元语法模型的错误率都至少是 1/2。
- 数字母的例子：非推理模型数不清 DEEPSEEK 里有几个 D；推理模型逐个字母拼出来就能数对。部分原因在于分词器把单词切成了 D/EEP/SEE/K 这样的 token。

3.3 其他因素

- 计算困难：再强的 AI 也不能突破计算复杂性，比如要求它"解密一段密文"。
- 分布偏移：问题与训练分布差异太大，例如"一磅羽毛和一磅铅哪个重"这类少见的问法。
- GIGO（垃圾进，垃圾出）：训练语料中的错误会被复刻。后训练能减少常见误解、阴谋论这类 GIGO 错误。

4. 后训练为什么没能消除幻觉

4.1 评测在奖励猜测

- 观察 1：对任何二元打分器（对 = 1，错或放弃 = 0），不论模型对正确答案持什么信念，最优策略永远不是放弃。
- 设想两个模型：A 会诚实地表达不确定、从不幻觉；B 与 A 一样，但从不表达不确定，不会就猜。在 0/1 计分下，B 的分数总是更高。
- 作者梳理了一批主流基准：GPQA、MMLU-Pro、IFEval、Omni-MATH、BBH、MATH、MuSR、SWE-bench、HLE 等几乎全是二元计分，而且对"我不知道"不给分。唯一的例外 WildBench 用 1 - 10 分的量表，但按其评分细则，"我不知道"的得分可能还低于带幻觉的"尚可"回答。
- 结论：只增加少量专门的幻觉评测不够，因为它们会被大量主流评测的信号"淹没"。

4.2 解法：显式置信目标

- 借鉴部分标准化考试（印度 JEE / NEET / GATE、美国 AMC，以及早年的 SAT、AP、GRE）的答错倒扣分规则。
- 做法：在每道题的指令里明确写出置信阈值 t。答对得 1 分，答错扣 t/(1−t) 分，回答"我不知道"得 0 分。常用的取值有 t = 0.5（答错扣 1 分）、0.75（扣 2 分）、0.9（扣 9 分）；t = 0 就退化成现在的二元计分。
- 简单计算可知：只有当模型认为自己答对的概率 > t 时，作答的期望得分才高于回答"我不知道"。
- 与以往工作相比有两点不同：

    1. 把阈值写进指令里。阈值公开之后，打分才客观，各家也更容易达成共识；而且可能存在一个在所有阈值下都最优的模型。
    2. 改造现有的主流评测（如 SWE-bench），而不是另起炉灶做专门的幻觉评测。

- 由此引出行为校准：不要求模型报出一个概率数字，而是要求它在每个阈值下都给出"自己至少有 t 把握"的最有用回答。可以通过比较不同阈值下的准确率和错误率来审计。

5. 讨论与局限

- 合理性与胡话：分析只考虑"看起来合理"的字符串，但加入"胡话"这一类后，定理仍然成立。
- 开放式生成：比如写传记，可以把"含有一个或多个错误"定义为出错，但更自然的做法是按错误数量分程度。
- 搜索和推理不是万能药：观察 1 对带 RAG 的模型同样成立。搜索没找到可靠答案时，二元计分仍然鼓励猜测；搜索也解决不了数字母这类内在错误。
- 隐含上下文：比如用户问"电话"时指的是座机，这类歧义超出了本文的框架。
- "对 / 错 / 不知道"的三分法也不完整，但总比只有"对 / 错"的二分法好，至少给了放弃的选项。
- 表达不确定不只有"我不知道"：还可以含糊其辞、省略细节、反问澄清。直接报概率（例如"我

有 1/365 的把握"）又会显得不自然，这涉及语用学问题。

6. 结论

- 预训练：生成错误和监督学习里的误分类同源，由交叉熵最小化自然产生。
- 后训练：大多数主流评测都在奖励幻觉行为。简单修改这些评测的打分方式，就能重新对齐激励，让"恰当表达不确定"得到奖励而不是惩罚。

7. 对本仓库 web-search-agent-go 的启示（个人解读）

- 本仓库的验收把失败文案（`IsFailureAnswer`）当作一种合法结果显式建模，这正是论文所说的"给'我不知道'留位置"。可以进一步给验收打分引入置信阈值：答错比放弃扣更多分。
- 论文提醒"搜索不是万能药"：当搜索结果不足以支撑答案时，应当鼓励 Agent 如实说明，而不是凭参数记忆猜一个。可以在系统提示里写明这一点，并在验收中加一条"证据不足时是否放弃作答"的断言。
- `experiment12` 的多次尝试结果，可以用来粗略观察"行为校准"：模型在高把握和低把握的问题上，选择放弃的比例是否不同。